INSTITUTO TECNOLÓGICO NACIONAL DE MÉXICO CAMPUS CULIACÁN

TOPICOS DE IA

Alumno:

Portillo Zuñiga Steve Javier

Unidad 3 Tarea 1

Hora: 10:00 – 11:00

Maestro: Zuriel Dathan Mora Felix

La Evolución Diferencial (Differential Evolution, DE) es un algoritmo de optimización estocástico y poblacional que pertenece a la familia de los algoritmos evolutivos. Fue propuesto por Storn y Price en 1997 como una alternativa eficiente para resolver problemas de optimización continua no lineal. Desde entonces, ha sido aplicado exitosamente en diversos campos como la ingeniería, economía, inteligencia artificial y diseño de sistemas.

A diferencia de otros métodos clásicos, la evolución diferencial no requiere derivadas ni continuidad en la función objetivo, lo que la convierte en una herramienta poderosa para resolver problemas complejos, con restricciones o funciones no diferenciables.

La Evolución Diferencial se basa en los principios de evolución natural, como la selección, mutación y recombinación. El algoritmo trabaja con una población de soluciones candidatas que evolucionan iterativamente en búsqueda del valor óptimo (mínimo o máximo) de una función objetivo.

El proceso se caracteriza por el uso de una operación de mutación diferencial, donde se genera una nueva solución utilizando la diferencia entre dos vectores de la población para perturbar un tercero. Esta técnica le permite explorar eficientemente el espacio de búsqueda.

Los fundamentos de la Evolución Diferencial se relacionan con los algoritmos genéticos y la optimización estocástica, pero difiere principalmente en el operador de mutación.

Los elementos clave de DE son:

- Población inicial: Se genera aleatoriamente dentro de los límites definidos del problema.
- Mutación: Se genera un vector mutante basado en la diferencia de otros vectores.
- Recombinación (cruce): Se mezcla el vector mutante con un vector de la población para generar un nuevo candidato.
- Selección: Se evalúa cuál de los dos vectores (original o nuevo) tiene mejor aptitud y se conserva para la siguiente generación.

Se define una población de NP vectores (soluciones) de dimensión D, generados aleatoriamente dentro del rango permitido:

$$X_i = [x_{i,1}, x_{i,2}, ..., x_{i,D}]$$

Para cada vector objetivo Xi, se eligen tres vectores distintos Xr1, Xr2,Xr3 y se genera un vector mutante Vi:

$$V_i = X_{r1} + F \cdot (X_{r2} - X_{r3})$$

donde $F \in (0, 2)$ es el **factor de escala.**

Se genera un nuevo vector Ui a partir de Vi y Xi mediante el cruce binomial:

$$u_{i,j} = \begin{cases} v_{i,j} & \text{si } rand_j \leq CR \text{ o } j = j_{rand} \\ x_{i,j} & \text{en otro caso} \end{cases}$$

donde $CR \in [0, 1]$ es la **tasa de cruce.**

Se evalúa la función objetivo f. Si el vector hijo es mejor, reemplaza al padre:

$$X_i = \begin{cases} U_i & \text{si } f(U_i) \leq f(X_i) \\ X_i & \text{en otro caso} \end{cases}$$

Un caso común para demostrar el uso de DE es la minimización de la función de esfera:

$$f(x) = \sum_{i=1}^{n} x_i^2$$

Esta función tiene su mínimo global en $x = [0, ..., 0]$, con $f(x) = 0$.

Aplicando DE, el algoritmo iterativamente mejora la población hasta encontrar valores cercanos a este mínimo.

Ventajas:

- Simple de implementar.
- No requiere derivadas.
- Eficaz en problemas complejos y no lineales.
- Capaz de evitar mínimos locales.

Desventajas:

- Depende de parámetros (como F, CR,NP).
- Puede ser lento si no se ajustan bien los parámetros.
- Requiere evaluación múltiple de la función objetivo (puede ser costoso).